

KAGGLE HACKATHON · DRUG-DISCOVERY ML

ChemAI: Predict the Cure

Предсказание биологической активности молекул против вируса гриппа
по RDKit-дескрипторам · IC50 · CC50 · SI

268.76

ФИНАЛЬНЫЙ RMSE НА KAGGLE

-97.1

ПУНКТА ОТ BASELINE(365.82)

750 / 250

СООТНОШЕНИЕ ОБУЧАЮЩЕЙ И ТЕСТОВОЙ
ВЫБОРКИ



КОМАНДА 27

Состав команды № 27

Тимлид:




Сединкин Михаил Алексеевич

Команда:

- *Вахненко Егор Васильевич*
- *Карбовский Денис Константинович*
- *Шемякин Игорь Игоревич*
- *Носов Максим Александрович*



EDA: основные графики



Распределения таргетов



EDA: три ключевых наблюдения



Сильная правосторонняя скошенность

Особенно у SI (max/median = 3905). RMSE тянет модель к среднему. Test должен быть центрированнее train — иначе LB не сойдется с OOF.



SI $\equiv$ CC50 / IC50 (точно)

В train тождество выполняется до $2e-11$. Это физика измерений. Используем как фичу в стекинге и для проверки physical impossibility.



Дубликаты строк

121 train row дублирует другие в descriptor space; ≈ 14 test rows имеют exact match в train. Источник исправления багов и аугментации.

Распределение таргетов (train)

target	min	p50	mean	p99	max
IC50	0.004	44.1	204.5	1334	4095
CC50	0.7	376.6	577.4	3162	4539
SI	0.011	4.0	89.2	1281	15620

Модели и архитектура



База — градиентный бустинг

LightGBM · XGBoost · CatBoost. Обучение и на $\log 1p(\text{target})$, и на raw-шкале. Multi-trim блендинг весов через SLSQP.



Diversity pack

ExtraTrees · Ridge · HuberRegressor · GaussianProcess — другой inductive bias для пробоя потолка GBT.



Stacking

IC50 ↔ CC50 обмениваются OOF; SI получает OOF $\text{IC50} + \text{CC50} + \log(\text{CC50}/\text{IC50})$.



Pseudo-labeling

Iterative: top-confident test rows как доп. данные. Расширенный teacher pool → точнее метки.



v2c SI stack

Отдельный LightGBM поверх base OOF + 192 дескриптора. 4 варианта гиперпараметров для блендинга.




Adaptive blending

Per-row: std предсказаний teachers → самые неуверенные строки получают min-of-teachers.



ФАЗА 1

Большой ансамбль: 365 → 278



Что зашло

- ✓ **Log-transform** снимает скос распределения (-42.7)
- ✓ **Two-stream log+raw** разные части распределения (-31.2)
- ✓ **Multi-trim SLSQP** устойчивее к test/train mismatch
- ✓ **Diversity pack** категориально разные модели — новый сигнал
- ✓ **v2c SI stack** нелинейный стэк поверх base OOF (-2.08)



НЕГАТИВНЫЕ РЕЗУЛЬТАТЫ

Что не зашло — и какие уроки

~40+ экспериментов с LB-валидацией

✗ L1/MAE loss, Optuna-tuning	+0.8...+1.1
✗ Linear calibration $a \cdot \text{pred} + b$	+0.1...+0.5
✗ Stacking поверх production	+2.6...+2.8
✗ Outlier downweighting	+0.35...+0.95
✗ Mixup / Residual modelling	OOF хуже
✗ Quantile mapping	OOF +30...+240
✗ Bigger teacher pool (5-8)	+0.05...+0.15
✗ External ChEMBL lookup	+8...+14 LB

«Model-tweak» регрессирует, «Information+» помогает

Подкрутка параметров улучшает OOF, но роняет LB. Новые фишки, метки, классы моделей — наоборот.

«Subset+» paradox

Похожие кандидаты (все GBT): меньше = лучше. Категориально разные: diversity полезна — правило переворачивается.

Test distribution $\neq$ train

trim_95 OOF — лучший proxy для LB. Но методы, меняющие train-распределение, делают OOF self-fulfilling.

Per-row adaptive > blanket

Все сплошные трансформации регрессировали. Точечная замена только uncertain строк — работает.



ФАЗА 2 · ПЕРЕЛОМ

Упрощение базы: 278 → ~272

Инсайт

Простые модели. Сложный ансамбль уперся в плато 282.6 (1500+ fits). Переписали базу с нуля.

- Только CatBoost + LightGBM, blend 0.75 / 0.25
- Без многоуровневого SLSQP
- Outlier removal: SI < 2000 → 746 rows
- Drop constant + corr > 0.95 → 159 фич
- 10-fold KFold, log1p только для SI

До → После

СЛОЖНАЯ БАЗА

~1500 fits / target

→ плато на 282.6 LB

ПРОСТАЯ БАЗА + v2c

271.7 LB

2 модели · 159 фич · скачок почти –7 пунктов от плато



ФАЗА 3

Multiseed и тонкая настройка: 272 → 268.76



3-seed averaging

Сиды 42 · 1337 · 2024. Усреднение OOF и test predictions снижает variance.

-1.5...-2.0 LB



Сужение adaptive pct

22% → 6% → 4% → 3.5%. Меньше строк уходит в min-of-teachers.

-3+ LB



Точные clips

IC50 на 98.80 перцентиле, CC50 на 98.95. Срезка хвоста предсказаний.

стабильный gain



268.76238

Финальный сабмит: H7 sweep (2026-05-29) — pct = 3.5% + CC clip 98.95. Регрессировали: 5-seed, pct 2/3/7%, blends, derived SI.



РЕШЕНИЕ

Финальный pipeline — 4 стадии

1

Multiseed base

CatBoost + LightGBM 75/25

3 seed × 10-fold KFold. Outlier removal SI<2000 (746 rows), 159 фич. log1p только для SI.



2

v2c SI stack

4 LGBM на расширенных фичах

192 дескриптора + OOF/pred IC50, CC50, SI. 4 варианта (baseline/conservative/wide/huber) × 3 seed.



3

Adaptive top-3.5%

min-of-teachers по uncertainty

log-std across 4 teachers. Топ-3.5% неуверенных → min. Остальные 96.5% → mean ансамбля.



4

Post-processing

Percentile clips

IC50 clip на 98.80, CC50 на 98.95 перцентиле test-предсказаний. Срезка тяжёлого хвоста.

Воспроизведение: `python solution.py — кэш multiseed base (~3 мин) · --mode full — полное обучение (~20 мин CPU)`



СВОДКА

Итоговая эволюция Public LB



ИТОГ

365.82

baseline HGB

268.76

финальный LB

-97.1

ПУНКТА УЛУЧШЕНИЯ

3 фазы · 60+ LB-сабмитов



ГРАНИЦЫ И РАЗВИТИЕ

Информационный потолок и пути роста



Узкое место в данных, не в моделях

LGBM, XGBoost, CatBoost, TabPFN дают предсказания с корреляцией 0.999+. Разные сиды, feature subsets, регуляризации — то же. Извлекли максимум сигнала из 192 дескрипторов и 750 примеров.



Больше данных

5000+ rows раскрыли бы TabPFN и pseudo-labeling.



Feature space через SMILES

Mordred (1800+), Morgan FP, GNN-эмбединги.



Multi-task learning

Shared embedding для корреляций IC/CC/SI.



Bayesian uncertainty

Deep ensemble / BNN
ВМЕСТО teacher disagreement.



Active learning

Oracle-лаборатория → информативные test rows.